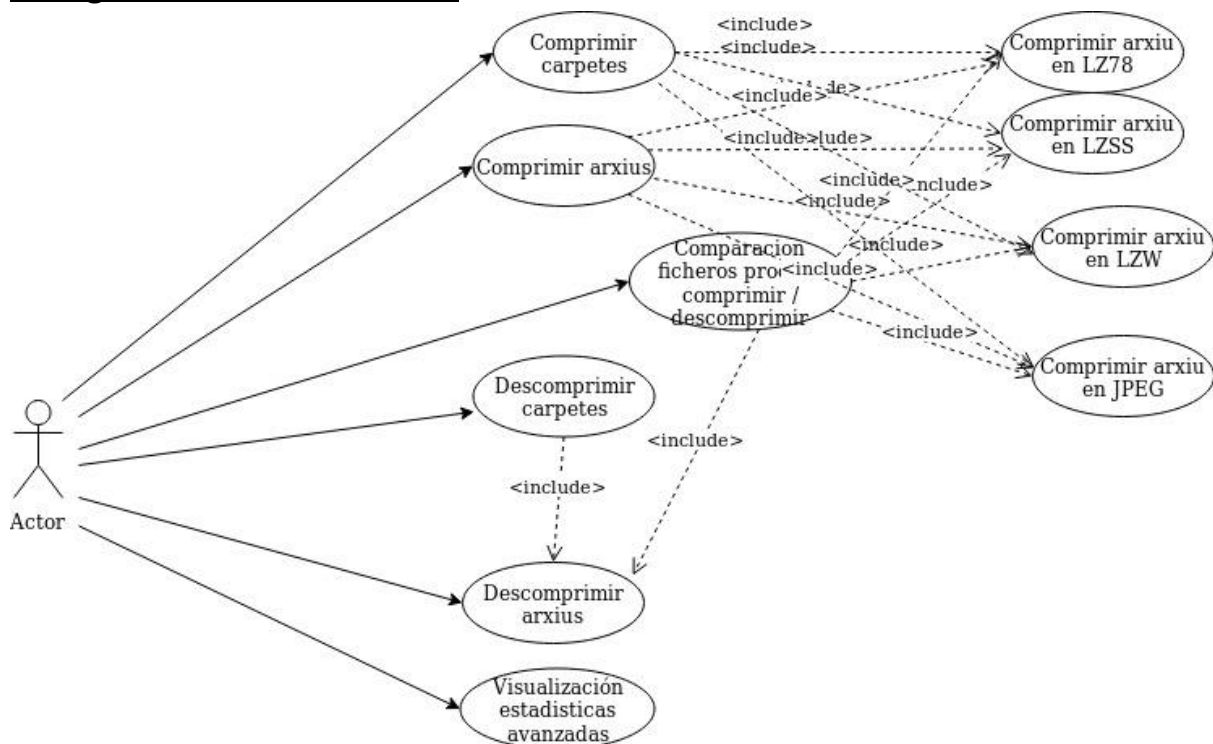


# PROP

Entrega 1

García Sánchez, Ivan  
Murciano Julia, Pau  
Navarro Albarracin, Juan Jose  
Pinilla Sanchez, Lucas

## Diagrama casos d'us



## Lista de funcionalidades

### Funcionalidades principales

Comprimir archivos en LZ78: Se comprime un archivo con el algoritmo LZ78 que. La extensión resultante sera xx.lz78.

Comprimir archivos en LZSS: Se comprime un archivo con el algoritmo LZSS. La extensión resultante sera xx.lzss.

Comprimir archivos en LZW: Se comprime un archivo con el algoritmo LZW. La extension resultante sera xx.lzw.

Comprimir archivos en JPEG: Se comprime un archivo con el algoritmo JPEG. La extension resultante será xx.jimg.

Comprimir archivo: El usuario pasa como input el path, escoge un algoritmo y indica si quiere guardarlo. Si el fichero no es xx.txt o xx.ppm, salta una excepcion. Si se ha seleccionado guardar, lo guarda en el sistema. Como output se muestran unas estadísticas básicas (tiempo de compresión y porcentaje de compresión).

Descomprimir archivos: El usuario pasa como input un path de un fichero comprimido y el sistema automaticamente detecta el algoritmo con el que fue comprimido y lo descomprime. Si el archivo tiene una extensión que no es lzso, lzss, lzw o cjpeg salta un error. Como output salen las estadísticas del fichero descomprimido.

Mostrar información estadística de los procesos de compresión/descompresión: Una vez acabado el proceso de compresión/descompresión, el usuario puede ver una serie de estadísticas. Estas son: la velocidad de compresión/descompresión, tiempo que ha tardado, porcentaje de compresión/descompresión y velocidad de compresión/descompresión.

Comprimir carpetas: el usuario pasa como input una carpeta y como output sale la misma carpeta con todo lo que contenía comprimido. El resultado es un único archivo comprimido que dentro tiene todos los archivos de la carpeta. El usuario tiene que escoger con qué algoritmo comprimir los archivos de texto y las imágenes. Puede elegir entre los siguientes algoritmos: LZ78, LZSS, LZW, JPEG. La extensión resultante será xx.cpt.

Descomprimir carpetas: el usuario pasa como input un archivo comprimido de tipo carpeta (xx.cpt) y si no es de este tipo salta un error. Como output sale la carpeta descomprimida.

Comparación fichero entrada/salida: El usuario inserta un fichero, el programa muestra por pantalla lo que tiene ese fichero por dentro y, una vez el usuario haya elegido el algoritmo, el programa muestra por pantalla el mismo fichero después de haber pasado por su correspondiente proceso de compresión y descompresión. (+ Visualizar estadísticas + que algoritmos se pueden usar).

Guardar archivo a disco: Una vez se ha comprimido o descomprimido el archivo, el usuario puede guardar si quiere el resultado en disco.

Salir: Se cierra el programa.

### **Funcionalidades secundarias**

Estadísticas generales de los algoritmos: El usuario elige uno de los cuatro algoritmos y como output le salen todas las estadísticas de ese algoritmo (porcentaje de compresión media, velocidad media, porcentaje de pérdida media). Si no se ha comprimido ningún archivo, sale todo ceros.

```

classDiagram
    class Arxiu {
        - path: string
        + Arxiu()
        + Arxiu(path: String)
        + getPath(): String
        + setPath(path: String)
        + getEstadistiques(): set(int)
        + setEstadistiques(e: Estadistiq)
    }
    class ArxiuBytes {
        - contingut: byte[]
        + ArxiuBytes(path:String, contingut : byte[])
        + getContingut(): byte[]
        + setContingut(contingut: byte[])
    }
    class ArxiuTXT {
        - contingut_chars: String[]
        + ArxiuTXT( path: String, contingut : String)
        + getContingut(): String
        + setContingut(contingut: String)
    }
    class Imatge {
        - version: String
        - sizeH: int
        - sizeV: int
        - maxVal: int
        + Imatge( path: String, contingut : byte []
        version: String, sizev: int, sizeh: int, maxValu
        + Imatge( path:String, contingut: byte[])
        - readLine(line: StringBuilder, pos: int, conte
        + getVersion(): String
        + getSizeH(): int
        + getSizeV(): int
        + getMaxVal(): int
        + getMida(): int
        + getHeader(): String
    }
    class ImatgeComprimida {
        - modifiedSizeH: int
        - modifiedSizeV: int
        - decoder: HashMap <String, Integer>
        - numPairs: int
        + ImatgeComprimida( path: String, contingut
        version: String, sizev: int, sizeh: int, maxValu
        modSizeV: int, modSizeH: int, dec: HashMap<
        Integer>, numPairs: int)
        + ImatgeComprimida( path:String, contingut :
        dec: HashMap<String, Integer> )
        + getModifiedSizeH(): int
        + getModifiedSizeV(): int
        + getNumPairs(): int
        + getDecoder(): HashMap<String, Integer>
        + getMida(): int
        + getHeader(): String
    }
    class Compressor {
        <<Abstract>>
        + getEstadistiques(temps_ini: long,):Estadi
    }
    class LZ78 {
        - unsignedToBytes(b: byte):int
        - intToByteArray(x: int):byte[]
        - byteArrayToInt(bytes: byte[]): int
        + comprimirArxiu(a: Arxiu): byte[]
        + descomprimirArxiu(a: Arxiu): byte[]
        + comprimirBandera(a: ArxiuTXT):Arxiu
        + comprimirBandera(a: ArxiuBytes):Arxi
    }
    class LZSS {
        + descomprimirArxiu(a: Archiu):A
    }
    class LZW {
        + comprimirArxiu(a: Archiu):Archiu
        + descomprimirArxiu(a: Archiu): Arch
        - genera_estadistiques(start: long, end
        tamIni: int, tamFi: int) : Estadistiques
    }
    class Estadistiques {
        - velocitat_compressio: double
        - percentage_compressio: double
        - percentage_decompressio: double
        + Estadistiques()
        + setVelocitat_compressio(velocitat_compressio: d
        + getVelocitat_compressio(): double
        + setTemps_compressio(temps_compressio: doubl
        + getTemps_compressio(): double
        + setPercentage_compressio(temps_compressio:
        + getPercentage_compressio(): double
        + getEstadistiques(): double[]
    }
    class EstadistiquesAlg {
        - num_compressions: double
        - num_descompressions: double
        + EstadistiquesAlg()
        + setNum_compressions(): double
        + setNum_descompressions(): double
        + getNum_compressions(): double
        + getNum_descompressions(): double
        + augmentaCompressions()
        + augmentaDescompressions()
    }
    class JPEG {
        - QcTable: int[]
        - normalizingScale: double[]
        - hsize: int
        - vsize: int
        - origVsize: int
        - origHsize: int
        + comprimirArxiu(a: Imatge): ImatgeComprimida
        + descomprimirArxiu(a: ImatgeComprimida): Imatge
        - RGBToYCbCr( byte[] content): float[][]
        - YCbCrToRGB(YCbCr: float[][]): byte[][]
        - subtract128(matrix: float[][]): float[][]
        - add128(matrix: float[][]): float[][]
        - doDCT(YCbCr: float[][] , actual: float[][] , a: int, b: int): float[][]
        - undoDCT(Quantized: float[][] , actual: float[][] , a: int, b: int): float[]
        - quantize(Quantized: float[][] , actual: int[][] , a: int, b: int): int[][]
        - dequantize(int[][] matrix) float[][]
        - runLengthEncode(mat: int[][] , row: int, col: int,
        result: ArrayList<Pair<Byte,Short>>): ArrayList<Pair<Byte,Short>>
        - runLengthDecode(mat: int[][] , decoded: int[][] , luminanc: int[][]): E
        - genera_estadistiques(start: long, end: long, tamIni: int, tamFi: int): E
    }
    class Pair {
        - first: T1
        - second: T2
        + Pair( a: T1, b: T2)
        + getFirst(): T1
        + getSecond(): T2
        + setFirst(a: T1)
        + setSecond(a: T2)
    }
    class ZigZag {
        - x: int
        - y: int
        - initialx: int
        - initialy: int
        - asc: boolean
        - mat: int[][]
        + ZigZag(content: int[][] , startx: int, st
        + isEnd(): boolean
        + getNextNumber(): int
        + writeNum(num: int)
        + getMatrix(): int[][]
        + nextSquare()
    }
    class Arxiu <--> ArxiuBytes
    class Arxiu <--> ArxiuTXT
    class Arxiu <--> Imatge
    class Arxiu <--> ImatgeComprimida
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
    class Arxiu <--> JPEG
    class Arxiu <--> Pair
    class Arxiu <--> ZigZag
    class Arxiu <--> EstadistiquesAlg
    class Arxiu <--> Compressor
    class Arxiu <--> LZ78
    class Arxiu <--> LZSS
    class Arxiu <--> LZW
    class Arxiu <--> Estadistiques
```

En primer lloc, hem creat una classe Arxiu per a identificar cada fitxer diferent amb el seu path al sistema. D'aquesta classe hem fet herencia a dues subclases, segons si el contingut ens interessa tenir-lo en bytes (Arxiu Bytes) o en una string (arxiuTXT). Dins el sistema hem hagut de diferenciar les fotos, ja que tenen diversos parametres que no tenen els arxius de text. Aquest son la versio de ppm, alçada de la foto, amplada de la foto i el valor maxím que té el ppm. La classe Imatge hereda de ArxiuBytes ja que tindrà el contingut en bytes. A més, hem hagut de diferenciar una imatge amb una imatge comprimida, ja que aquesta a més de tenir els valors d'una imatge, ha de guardar el tamany modificat, ja que ha de ser múltiple de 8, i també ha de guardar el traductor de la compressió per utilitzar-lo a l'hora de descomprimir.

També hem creat la classe Estadístiques, ja que cada arxiu tindrà les seves un cop hagin acabat de ser comprimits o descomprimits. Les estadístiques que mostrarem per aquesta primera entrega seran la velocitat de compressió, el percentatge que ha comprimit/descomprimit i el temps que ha trigat en fer-ho.

Un altre classe que hem fet ha estat la classe compresor, classe a la qual delegarem la responsabilitat de comprimir/descomprimir. Com a fills tindrà un per cada algoritme (LZ78, LZSS, LZW i JPEG). Tots aquests tindran unes estadístiques generals segons les mitjanes de totes les compresions i descompresions realitzades per aquests. Aquesta funcionalitat la donarem de cara a la segona entrega.

Hem creat una classe encarregada d'accedir als arxius de disc, ja sigui llegir-los o escriure el contingut en un. Aquesta classe simularà la capa de persistència.

I per últim, tenim els controladors que serveixen per connectar la capa de presentació amb la capa de domini.

# ALGORITME LZW

Fet per Ivan Garcia Sanchez

## Introducció

Aquest algoritme es un algoritme de compressio sense perdua creat al 1984 per Abraham Lempel, Jacob Ziv i Terry Welch. Es un algoritme molt utilitzat en la compressio d'arxius en Unix i per comprimir imatges en format GIF.

## Descripcio de l'algoritme

### Proces de compressió

L'algoritme tracta de generar un diccionari de manera dinamica segons les repeticions que troba al text i les assigna un valor de menys tamany que identificara aquesta cadena al text comprimit.

Primer genera un diccionari amb 256 entrades, una per cada caracter ASCII.

Un cop inicialitzat el diccionari, va buscant repeticions de text que ja havien aparegut abans. El metode és el següent:

Llegeix un caracter i el fusiona amb el que havia anteriorment. Aquesta fusio mira si ja te una entrada al diccionari. Si ja la te, aquesta fusio passa a ser el que havia anteriorment per a que sigui fusionat amb el següent caracter. Altrament, afegeix una entrada nova al diccionari amb aquesta fusio assignant-li un nou valor diferents a la resta de entrades, afegeix al resultat de la compressio la traduccio del que havia anteriorment i aquest caracter passa a ser el que hi havia anteriorment.

Aquest diccionari tindra les entrades limitades, porque sino hi haura errors a l'hora d'escriure el contingut en un fitxer.

Quan ja no hi ha mes caracters al contingut, afegeix al resultat la traducció del que havia anteriorment.

### Procés de descompressió

El proces de descompressio es generar el diccionari tal i com s'havia generat en el proces de compressio.

Inicialment s'inicialitza el diccionari amb 256 entrades, una per cada caracter ASCII.

Despres llegeix el primer codi de la traduccio, posa al resultat la seva traduccio i guarda el codi en codi antic.

A partir d'aquí ja itera sobre tots els codis de traduccio del contingut. Si el codi nou esta al

diccionari, es fica al resultat la seva traducció i fem al diccionari una entrada nova amb un nou codi de compressió i com a contingut la traducció del codi antic fusionada amb el primer caràcter de la traducció del codi nou. Altrament, l'únic que canvia és que al resultat fem la fusió de la traducció del codi antic i el primer caràcter de la traducció del codi nou. Finalment posem codi nou en codi antic.

### Estructura de dades utilitzades

Les estructures de dades que he utilitzat són les següents:

- **HashMap:** He utilitzat aquest tipus d'estructura de dades per a que faci el paper de diccionari de traduccions als processos de compressió i descompressió. He utilitzat el HashMap perquè el cost de totes les crides són de cost  $O(1)$ , aportant-me major velocitat a l'algoritme. Podia haver utilitzat TreeMap però aquesta estructura de dades és més lenta en les operacions de get i put ( $O(\log(n))$ ) i a més, no necessito el map ordenat per les claus.

### Pseudocodis

#### Comprimir

```
1 Initialize table with single character strings
2   P = first input character
3   WHILE not end of input stream
4     C = next input character
5     IF P + C is in the string table
6       P = P + C
7     ELSE
8       output the code for P
9       add P + C to the string table
10      P = C
11    END WHILE
12  output code for P
```

- 1- Inicialitzem el diccionari amb una entrada per cada caràcter ASCII.
- 2- Llegim el primer caràcter del contingut.
- 3- Iterem per tot el contingut.
- 4- Llegim el següent caràcter del contingut.
- 5- Mirem si ja s'havia trobat abans la combinació de caràcters anteriors concatenat amb el caràcter actual.
- 6- la combinació de caràcters anteriors passa a ser la que hi havia concatenada amb el caràcter actual.
- 7- Tractament si no es troba al diccionari la combinació de caràcters anteriors concatenat amb el caràcter actual.
- 8- Fem la traducció de la concatenació de caràcters anteriors al resultat.

- 9-Afegixes a una nova entrada del diccionari la combinacio de caracters anteriors concatenat amb el caracter actual amb un codi diferent a la resta.
- 10- Posem com a combinacio de caracters anteriors el caracter actual.
- 11-Tornem al 3 per seguir iterant per tots els caracters del contingut.
- 12- Un cop ja hem recorregut tot el contingut, fiquem la traducció de la concatenacio de caracters anteriors al resultat.

### Descomprimir

- 1 Initialize table with single character strings
- 2   OLD = first input code
- 3   output translation of OLD
- 4   WHILE not end of input stream
- 5     NEW = next input code
- 6     IF NEW is not in the string table
- 7       S = translation of OLD
- 8       S = S + C
- 9     ELSE
- 10      S = translation of NEW
- 11    output S
- 12    C = first character of S
- 13    OLD + C to the string table
- 14    OLD = NEW
- 15 END WHILE

- 1- Inicialitzem el diccionari amb una entrada per cada carактер ASCII.
- 2-Llegim el primer codi del contingut comprimit.
- 3-Afegim al resultat la traducció d'aquest codi, es a dir, el contingut original.
- 4-Iterem per cada codi del contingut comprimit.
- 5-Llegim el nou codi del contingut.
- 6- Mirem si el nou codi ja esta al diccionari.
- 7- Fiquem a una variable S la traducció corresponent al codi antic.
- 8- Concatenem la traducció del codi antic amb el primer carактер de la traducció de codi antic.
- 9-Mirem si el codi nou no esta al diccionari.
- 10-Fiquem a una variable S la traducció corresponent al codi nou.
- 11-Afegim al resultat el conjunt de caracters de la variable S.
- 12-Consequim primer caracter que s'ha afegit al resultat.
- 13-Fiquem en una entrada nova del diccionari amb la traducció del codi vell mes el caracter aconseguit a la linea 12.
- 14-Assignem el codi nou a codi vell.
- 15- Repetim per a tots els codis del contingut comprimit.



# Algoritme LZ78

Fet per Lucas Pinilla Sánchez

## Introducció

El LZ78 es un algorisme de compressio de dades sense perduda basat en el LZ77. El seu funcionament es basa guardar una sequencia de caracters que apareixen en un text en una estructura de dades que es crea tant en el metode comprimir com descomprimir i es simetrica.

## Descripcio del algorisme

### Compressio

Aquest algorisme recorre el text i genera un diccionari que va omplint a mesura que es troba amb una sequencia de caracters no reconeguda previament.

Si hi ha un carактер que no es troba al diccionari l'emagatzema i es s'escriu al arxiu comprimit amb la posició 0. En cas contrari, es guarda la posicio del diccionari on es troba i s'accedeix al següent carактер, així repetidament fins que la sequencia no es troba dins del diccionari, llavors enmagatzema la ultima lletra conjuntament amb la posicio on es troba la resta de la sequencia.

Per optimitzar el codi s'ha fet servir un byte anomenat flag o bandera que ens permet saber si la posicio es pot codificar amb un sol byte o si pel contrari el map te mes de 255 entrades i ens calen dos bytes. Aquest byte indica amb un 0 si es pot codifar amb un o un 1 en cas contrari.

### Descompressio

Primer de tot es llueix el byte de flag que ens permet saber com hem de llueix les següents 8 parelles de posicio i carактер. Es llueix 8 parelles calculant la posicio segons el bit de flag que va de major a menor pes.

Si la posicio es 0 s'escriu el carактер i s'afegeix al diccionari.

Si la posicio no es 0, es busca al diccionari la sequencia corresponent a la posicio i se li suma el carактер que l'acompanya, s'escriu i s'afegeix al diccionari la nova sequencia.

El diccionari va creixent a mesura que es llueix un parell de l'arxiu comprimit i es simetric al diccionari que es crea al proces de compressió.

### Estructura de dades utilitzada

Per fer el algorisme s'ha ulitzat un hashmap per enmagatzemar tant al proces de compressio com descompressio les sequencies de caracters ja accedides previament.

He fet servir aquesta estructura de dades ja que he considerat que era que millor s'adapta a les necessitats del algorisme.

En el proces de compressio he fet servir una llista, degut a que la clau del map es la sequencia de caracters i que es interessant poder borrar elements del map d'una posicio determinada per temes d'eficiencia. La llista permet mantenir una relacio durant tot el proces de compressio de la posicio amb la clau del map.

## PSEUDOCODI

### Compressio

```
begin
    ini diccionario
    while(data not null)
        begin
            actual = inicial +a
            if act in map then
                ini = a; pos = map.get(pos)
            else map.put(act), write(pos,a)
        end
    end
end
```

### Descompressio

```
begin
    Inicializar diccionario
    while(data not empty)
        begin
            read pos and character
            insertar nueva frase en diccionario con map(pos) + character
            escribir en el resultado nueva palabra
        end
    end
end
```

# Algoritme LZSS

Fet per Juan Jose Navarro Albarracin

## Introducció

L'algoritme LZSS (Lempel-Ziv-Storer-Szymanski) es un algoritme de compresio sense perdues derivat del LZ77 i creat en 1982 por James Storer y Thomas Szymanski. Els compressors basats en algorismes sense perdua s'utilitzen quan la informacio a comprimir es critica i no es pot perdre informacio.

## Descripcio de l'algorisme

### Compresio

Aquest algorisme utilitza una finestra de desplaçament que es divideix en dos parts: un buffer d'anticipacio, que guardara els caracters que volem codificar i un buffer de cerca, que es la finestra on buscarem les repeticions iguals a les del buffer d'anticipacia.

Per a comprimir, codifiquem el text de la següent manera. Busquem la mateixa sequencia que tenim al buffer d'anticipacio, al buffer de busqueda. Si la trobem codifiquem 2 bytes que contindran la posicio d'inici de la repeticio i la longitud d'aquesta. Si no la trobem, codifiquem un carактер normal, igual que el llegit.

A part d'aquesta codificacio utilitzarem un byte anomenat flag, on guardarem un 0 si no hem codificat el caràcter i un 1 si hem codificat posicio i desplaçament. Com un byte conte 8 bits, podrem codificar 8 repeticions/caracters en cada byte.

### Descompressió

Per a descomprimir només utilitzarem un buffer de busqueda on anirem buscant les repeticions codificades. Primer es llegeix el byte bandera. Agafem bit a bit per a saber si hem de decodificar una posició+desplaçament o només un caràcter.

Si el bit es 0 guardarem el caràcter al buffer de cerca.

Si el bit es 1 llegim la posicio i el desplaçament. Un cop tenim la posicio anem al buffer de cerca a la posició indicada i llegim tants caracters com indica el desplaçament.

## Estructures de dades utilitzades

En aquest algorisme hem utilitzat les següents estructures de dades:

- **Diccionari:** Hem utilitzat un diccionari per a guardar els diferents caracters que anem guardant al buffer de cerca. L'implementacio d'aquest diccionari es amb apuntadors als caracters següents, per tant te una estructura d'arbre. Hem fet servir aquesta estructura perquè la cerca de la clau te un cost molt petit.

- **Arbre:** Hem utilitzat aquesta estructura per a implementar el diccionari. D'aquesta forma tenim un diccionari estructurat caracter a caracter on cada node es un sol caracter i esta conectat amb el seu consecutiu. Hem fet servir aquesta estructura porque la cerca es fa molt més sencilla i rapida.
- **Llista:** Estructura utilitzada per a implementar els nodes que te cada pare de l'arbre, es a dir, per a saber amb quins caracters es conecta cada caracter. Hem utilitzat llistes porque per a afegir es més rapid que no un array.
- **Array:** Hem utilitzat aquesta diverses vegades amb diferents tipus de dades. Un tipus de dades son char, on guardem els caracters que hem codificat o els que volem codificar. Altre tipus són byte, ja que l'utilitzarem per a guardar tots els bytes que formaran el contingut del fitxer comprimit.

## Pseudocodi

### Comprimir

```

1 Inicialitzem totes les estructures i omplim el buffer d'anticipació
2   PA = BC
3   WHILE TC > 0
4     IF PA.D < MIN_C
5       E = E+C
6       F = F << 1
7     ELSE
8       F = (F << 1 OR 1)
9       E += PA.P + PA.D
10    END IF
11    CB = CB + 1
12    WHILE i < PA.D AND PL < TC
13      DIC = DIC + C
14      SW = SW + C
15      LA = LA + NEW(C)
16    END WHILE
17    WHILE i < PA.D
18      DIC = DIC + C
19      SW = SW + C
20      TC = TC - 1
21    END WHILE
22    IF CB >= 8 OR TC == 0
23      S = S + E
24      CB = 0
25    END IF
26    IF TC > 0
27      P = BC
28    END IF

```

```

29     IF PC BETWEEN (PA.P AND PA.P+PA.D)
30         PA.D= PC - PA.P
31     END IF
32 END WHILE
33 EST = CE

```

1. Inicialitzem totes les estructures de nou i SlidingWindow ho omplim amb un caràcter indicatiu (fara de controlador aquest caràcter)
2. Realitzem la busqueda de coincidència i el resultat ho guardem a un par
3. Mentre el tamany llegit sigui major a 0
4. Si el desplaçament del par és menor que el mínim per codificar
5. Guardem a la variable escriure el caràcter a imprimir
6. Fem un shift left amb el byte flag
8. Desplaçem el byte Flag a l'esquerra i fem una or amb un 1 per posar el bit a 1
9. Afegim a escriure, els bytes de posició+desplaçament
11. Aumentem el contador de bits en 1 i posem la i a 0
12. Mentre que la i(variable per bucles) sigui menor que el desplaçament i la posició per llegir menor que el final del contingut entra al bucle
13. Afegim el caràcter codificat al diccionari
14. Afegim el caràcter al buffer de cerca(SW)
15. Afegim al buffer d'anticipacio(LA) una nova lletra per a codificar del contingut
17. Mentre i sigui menor al desplaçament (vol dir que hem arribat al final del fitxer)
18. Afegim el caràcter codificat al diccionari
19. Afegim el caràcter codificat al buffer de cerca
20. Disminuim el tamany a codificar en 1
22. Si el contador de bits és 8 o més i el tamany a codificar no és 0 entra
23. Escribim a la sortida el byte flag seguit del contingut a escriure
24. Resetegem el contador de bits i el byte flag
26. Si el tamany a codificar és > 0 entra
27. Busquem la següent coincidència i ho guardem al par P
29. Si la posició de guardar al buffer de cerca es troba entre la posició de la coincidència i la posició de la coincidència+desplaçament
30. Cambiem el desplaçament a la (posició contingut - posició inicial repetició)

## Descompressor

```

1 Inicialitzem totes les estructures
2 IF TAMC == 0 RETURN A
3 F = C[0]
3 WHILE i < TAMC
4     B = F >> PF
4     IF B == 0
5         CH = C[i]
6         S += CH
7         SW += CH

```

```

8         i++
7     ELSE
8         P = leer(C[i], C[i+1])
9         FOR j < P.D
10            S += SW[P.P]
11            SW[c] = SW[P.P]
12        END FOR
13        i+=2
14    END IF
15    IF PF < 0 AND i<TAMC
16        F = C[i]
17    END IF
18    RETURN (path, S)

```

- 1 Inicialitzem totes les estructures noves per a netejar les possibles dades
- 2 Si el tamany del contingut es 0, retornem un arxiu buit
- 3 Agafem el flag que es el primer byte del arxiu
- 3 Mentre la i sigui menor al tamany del contingut
- 4 Agafem el bit de la posicio que necessitem i ho guardem a bandera
- 5 Si aquesta bandera es 0
- 6 Guardem a caracter el caracter del contingut[i]
- 7 Escribim a la sortida el caracter
- 8 Guardem al buffer de cerca el caracter
- 9 Aumentem la i en 1
- 11 Guardem el resultat de llegir els 2 bytes posicio i desplaçament al par
- 12 si la j es més petita que el desplaçament
- 13 Guardem a la sortida el contingut de la posicio del par
- 14 Guardem el contingut de la posicio del par al buffer de cerca
- 16 Aumentem en 2 la i
- 18 Si la posicio del flag es mes petit que 0 i la i es mes petita que el tamany del contingut
- 19 Guardem al flag el contingut de la posicio i
- 21 Retornem un arxiu amb el path canviat i el contingut de sortida

# Algoritme JPEG

Fet per Pau Murciano Julia


## Introducció

L'algorisme JPEG es un algorisme de compresio d'imatges *lossy* (amb perdues) creat per el Joint Photographic Experts Group (JPEG) a l'any 1992. Actualment es fa servir per a poder transportar qualsevol tipus d'imatge amb una mida molt més petita.

## Descripcio de l'algorisme

### Compressio

En l'estat inicial, es te les tres components originals de la imatge descomprimida (component vermella (R), component verda (G), i component blava (B)) per separat. En primer lloc, el que es fa es transformar les tres components inicials en una altra base de colors, la base YCbCr (Iluminancia (Y), diferencia de color blau(Cb) i diferencia de color vermell(Cr)). Això es fa perquè l'ull huma es molt sensible als canvis de llum (Y) pero no als de color (Cb i Cr) aixi que podem comprimir aquestes dues ultimes components.



$$\begin{pmatrix} Y \\ Cb \\ Cr \end{pmatrix} = \begin{pmatrix} 0.299 & 0.587 & 0.114 \\ -0.169 & -0.334 & 0.500 \\ 0.500 & -0.419 & -0.081 \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix} + \begin{pmatrix} 0 \\ 128 \\ 128 \end{pmatrix}$$

*Fórmula per passar de RGB a YCbCr*

En segon lloc, per a poder fer canvis que no noti l'ull huma el que es fa dividir la imatge en matrius de 8 pixels x 8 pixels i mitjançant la DCT (Transformacio Discreta del Cosinus), interpretar cada matriu com una ona.

$$G_{u,v} = \frac{1}{4} \alpha(u) \alpha(v) \sum_{x=0}^7 \sum_{y=0}^7 g_{x,y} \cos \left[ \frac{(2x+1)u\pi}{16} \right] \cos \left[ \frac{(2y+1)v\pi}{16} \right] \quad \alpha(u) = \begin{cases} \frac{1}{\sqrt{2}}, & \text{if } u = 0 \\ 1, & \text{otherwise} \end{cases}$$

### Fórmula de DCT

En tercer lloc, el que es fa es quantitzar el resultat de la matriu, es a dir, eliminar les freqüències altes de cada ona, ja que son les que l'ull huma menys nota. Per fer-ho es divideix cada pixel de les matrius de 8x8 entre el seu pixel corresponent a la matriu de quantització.

$$Q_c = \begin{pmatrix} 17 & 18 & 24 & 47 & 99 & 99 & 99 & 99 \\ 18 & 21 & 26 & 66 & 99 & 99 & 99 & 99 \\ 24 & 26 & 56 & 99 & 99 & 99 & 99 & 99 \\ 47 & 66 & 99 & 99 & 99 & 99 & 99 & 99 \\ 99 & 99 & 99 & 99 & 99 & 99 & 99 & 99 \\ 99 & 99 & 99 & 99 & 99 & 99 & 99 & 99 \\ 99 & 99 & 99 & 99 & 99 & 99 & 99 & 99 \\ 99 & 99 & 99 & 99 & 99 & 99 & 99 & 99 \end{pmatrix}$$


Matriu de quantització

$$F(u,v)_{Quantization} = round\left(\frac{F(u,v)}{Q(u,v)}\right)$$

Fórmula de quantització

En quart i últim lloc, es fa una codificació entropica de cada matriu, la qual es divideix en dues parts, el RLE (Run Length Encoding) i aplicar codificació huffman al resultat.

Per aplicar poder fer el Run Length Encoding, primer hem de recorre la matriu de forma en la que puguem treure mes zeros seguits possibles, ja que eliminarem els 0s. Aquesta forma consisteix en recorre la matriu en zig-zag de la següent forma:



Recorregut en zig-zag d'una matriu

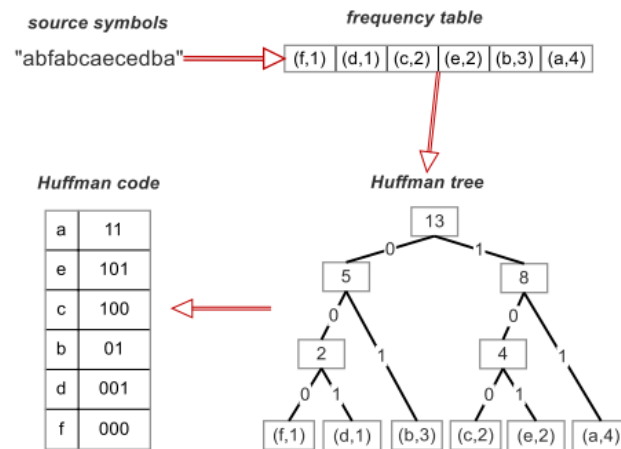
Un cop haguem fet això, tindrem una tira de pixels amb uns valors que com mes al final estiguem mes zeros hi haura, així que per cada valor que trobem diferent de 0, treurem el següent parell de valors (Numero de 0s abans del valor, valor). Quan s'arriba al final de la matriu, es posa un parell especial, que es el parell (0,0), que serveix per indicar fi de matriu.

Un cop es té tota la tira de parells es pot aplicar la codificació huffman al resultat. Per fer-ho el que es fa es comptar quantes vegades apareix cada parell de valors en tota la tira de parells i ordenar per menor freqüència. Quan ja es té ordenat per menor freqüència, es construeix un arbre de la següent forma: Cada parell de valors amb la seva freqüència es un node, i mentre hi hagi nodes disponibles i tots no formin un arbre, s'agafen els dos nodes amb menor freqüència i s'ajunten en un que la seva freqüència es la suma dels seus dos nodes fills.

Una vegada ja es té l'arbre format, es crea el codi de codificació per a cada parell de valors



de la següent forma: Començem al node arrel, i si anem cap a l'esquerra posem un 0 si anem a l'esquerra o un 1 si anem a la dreta. Després per a cada node fill, es fa el mateix, i s'afegeix cada número a la dreta de l'anterior. Quan ja es té tots els codis, es posen en una taula i es procedeix a substituir cada parell de valors per el seu codi i es guarda.



Procés de codificació huffman

## Descompressio

Per a descomprimir un arxiu només hem de desfer els passos que hem fet per a codificar-lo. En primer lloc, es desfa els codis huffman, es a dir, es va llegint els codis i per a cada codi es guarda el seu parell equivalent.

Un cop es tenen tots els parells, es desfa el RLE recorrent la matriu en zig zag i com que tenim totes les dades (el número de 0s abans de cada valor i el valor que no és 0), es reconstrueix cada matriu de 8 pixels x 8 pixels.

Quan ja es té cada matriu de 8x8, es desquantitza i per tant es multiplica cada número de la matriu per el seu equivalent a la matriu de quantificació i es recupera una aproximació del seu valor real.

$$F(u, v)_{deQ} = F(u, v)_{Quantization} \times Q(u, v)$$

Formula de desquantització

Una vegada es té la imatge desquantitzada, es desfa la DCT que s'ha fet al codificar i s'obtenen les components YCbCr.

$$f_{x,y} = \frac{1}{4} \sum_{u=0}^7 \sum_{v=0}^7 \alpha(u)\alpha(v)F_{u,v} \cos\left[\frac{(2x+1)u\pi}{16}\right] \cos\left[\frac{(2y+1)v\pi}{16}\right]$$

Formula inversa de DCT

Finalment, es passa de YCbCr a RGB i ja es té la imatge descomprimida.

$$\begin{aligned}
 R &= Y + 1.402 \cdot (C_R - 128) \\
 G &= Y - 0.34414 \cdot (C_B - 128) - 0.71414 \cdot (C_R - 128) \\
 B &= Y + 1.772 \cdot (C_B - 128)
 \end{aligned}$$

Formula per passar de YCbCr a RGB

### Estructures de dades utilitzades

Les estructures de dades que he fet servir son les següents:

- HashMap: L'he fet servir per a guardar la associació dels codis huffman amb el parell de valors. L'he triat perquè el que vull fer es moltes cerques de valors dins de l'estructura de dades sense importar l'ordre que tenen els valors. Per aquesta tasca la millor estructura de dades es una taula de Hash, ja que el cost mig de les cerques es constant ( $O(1)$ ) i l'estructura que ho representa a Java es el HashMap.
- PriorityQueue: Aquesta estructura de dades s'ha fet servir per muntar l'arbre en el proces de creacio dels codis huffman. L'he triat perquè necessito tenir en tot moment els valors dels nodes ordenats, i la priority queue, que s'implementa amb un heap (en aquest cas es un min-heap), es el que millor va. Si fos una altra estructura, quan vulguessim inserir un nou node, hauriem de reordenar la estructura sencera (cost  $O(n \cdot \log(n))$ ) o mirar d'inserir-la en un lloc correcte (cost  $O(n)$ ), en vers al cost d'inserir un valor nou a un heap ( $O(\log(n))$ ).
- Arbre: En el cas d'aquesta estructura de dades, s'ha triat perquè es la que es fa servir per a muntar els codis en el proces de codificació huffman.
- ArrayList: Aquesta estructura de dades l'he fet servir quan he de tenir una llista de elements pero no se quants elements seran, i per tant necessitava que pogues creixer.
- Array: L'he fet servir per tractar les matrius de dades de la imatge i en tots els casos en els que he hagut de guardar elements quan si que sabia el total d'elements que hi hauria.

### Pseudocod

#### RunLengthEncoding

##### Encode

```

1 FUNCTION RLEEncode (matrix)
2   resultat = cjt buit
3   CONTADOR = 0
4   WHILE NOT end of matrix reached
5       newValue = nextZigZagValue();
6       IF newValue = 0
7           contador = contador + 1
8       ELSE

```

```

9             tuple = {contador,newValue}
10            resultat.add(tuple)
11            contador = 0
12        END IF
13    ENDWHILE
14    resultat.add({0,0})
15 RETURN resultat

```

El que fa aquesta funció és per una matriu de 8x8, la recorre fent zig zag (tal i com es mostra a la foto de l'explicació del run length encoding, i si el valor és zero, incrementa el comptador, sino, guarda en un conjunt, un parell de valors que és el número de zeros que es portava i el valor diferent de zero. Al final fem un parell amb dos zeros per a marcar el final de la matriu.

Decode

```

1 FUNCTION RLEDecode(data)
2     resultat = matrix
3     FOR p IN data
4         IF p == {0,0}
5             resultat.acabaSubMatriu()
6         ELSE
7             resultat.writeInZigZag(p.numZeros)
8             resultat.write(p.numDifZero)
9         ENDFOR
10    RETURN resultat

```

Aquesta funció el que fa és per a cada parell, de que li entra, si és el parell {0,0}, escriu amb zeros tot el que queda de la submatriu. Si no, escriu tants zeros en zig zag com la primera component del parell i després escriu el número diferent de zero a la següent posició del zig zag.

Huffman

Creació arbre

```

1 FUNCTION CrearArbre (data)
2     contats = cjt buit
3     FOR d IN data
4         IF contats.contains(d)
5             contats[d] = contats[d].frequencia + 1
6         ELSE
7             contats.add(d,0)
8         ENDIF
9     ENFOR
10    PrioQueue = contats
11    WHILE PrioQueue .size() is not equal to 1
12        node = new node()
13        node.left = PrioQueue .pop()

```

```

14         node.right = PrioQueue .pop()
15         node.frequencia = node.left.frequencia + node.right.frequencia
16         PrioQueue.push(node)
17     ENDWHILE
18 RETURN PrioQueue.pop()

```

Aquesta funció el que fa és en primer lloc, comptar quants parells hi ha de cada parell en totes les dades i després es construeix l'arbre de huffman. Per construir-lo, agafa els dos nodes amb menys freqüència i els uneix en un que té la suma de les dues freqüències i el torna a ficar al conjunt de nodes. Un cop només queda un node, l'arbre ja està construït.

#### Creació codis

```

1 FUNCTION crearCodis (nodeArbre,codi)
2     IF nodeArbre.left == empty AND nodeArbre.right == empty
3         RETURN result = codi
4     ELSE
5         codisLeft = crearCodis(nodeArbre.left,codi+"0")
6         codisRight = crearCodis(nodeArbre.right,codi+"1")
7         RETURN UNION(codisLeft,CodisRight)
8     ENDIF
9 END

```

Aquesta funció el que fa és crear els codis de huffman per a codificar de la següent forma. Començant des de l'arrel, es mira si té fills. Si no en té, es retorna el codi construït fins a ell. Si en té, es construeix els codis dels fills, fent hi un zero o un u a la dreta segons si és el fill esquerra o dret, respectivament. Un cop es tenen els codis dels fills, s'ajunten els sets de codis i es retornen.

#### Codificar contingut

```

1 FUNCTION buildCodes (codifier, data)
2     resultat = cjt buit
3     FOR d IN data
4         resultat.append(codifier[data])
5 RETURN resultat

```

Per a codificar el contingut, el que es fa és per a cada parell de dades a data, es busca el seu codi al codificador i s'afegeix al resultat. Un cop s'han codificat tots els resultats, es retorna el resultat amb tot codificat.

#### Decodificar contingut

```

1 FUNCTION decode(decodifier,data)
2     resultat = cjt buit
3     codi = buit
4     FOR bit IN data
5         codi.append(bit)

```

```
6         IF decodifier.conte(codi)
7             resultat.add(decodifier[codi])
8             codi = buit
9         ENDIF
10    ENDFOR
11 RETURN resultat
```

Per a decodificar les dades, es va construir un codi amb cada bit que entra per les dades, i si existeix el codi al decodificador, s'afegeix el parell decodificat al resultat i es reinicia el codi construït. Es fa això fins que no queden bits i es retorna el contingut decodificat.

*\*No s'ha inclòs el pseudocodi de les operacions de passar de RGB a YCbCr i el seu pas invers, ni tampoc les operacions per fer la DCT i la seva inversa perquè són fórmules.*